

Лекция 1.

Теория вероятности изучает характеристику случайных величин, тогда как математическая статистика решает обратную задачу

Допустим, что у нас есть случайная величина, по ней мы можем найти математическое ожидание, моменты и оценить, какое распределение имеет случайная величина.

Выборки

Def. Выборка – набор данных, полученных в ходе экспериментов. Тогда количество экспериментов n – объем Выборки

Def. Генеральной совокупностью называются все результаты проведенных экспериментов

Def. Выборочной совокупностью называются наблюдаемые данные экспериментов

Не все данные экспериментов мы можем наблюдать, например, выборы, тогда опросы голосовавших – выборочная совокупность, а результаты выборов – генеральная. Очевидно, что выборочная и генеральная совокупности могут иметь различные распределения.

Def. Выборка называется **репрезентативной**, если ее распределение близко к распределению генеральной совокупности

Пример – **ошибка выжившего**. Во время Второй Мировой стал вопрос, в каких местах стоит бронировать корпус самолета. Самолеты возвращались с пулевыми отверстиями, и интуитивно казалось, что стоит бронировать те места, которые больше всего пострадали. Однако не были учтены те самолеты, которые не вернулись, а те, которые выжили, выжили благодаря тому, что были прострелены в нелетальных местах, поэтому было принято решение бронировать фюзеляж в менее пострадавших местах

В дальнейшем считаем, что все выборки репрезентативны

Def. 1. Выборкой объема n называется набор из n экспериментальных данных $\vec{X} = (x_1, x_2, \dots, x_n)$ (апостериорное определение)

Def. 2. Выборкой объема n называется набор из n независимых одинаково распределенных случайных величин $\vec{X} = (X_1, X_2, \dots, X_n)$ (априорное определение)

Выборочные характеристики

Можно выборку рассматривать как дискретную случайную величину с одинаковыми вероятностями $p_i = \frac{1}{n}$ и вычислить для нее математическое ожидание, дисперсию и функцию распределения

Def. Выборочным средним $\bar{x}$ называется величина $\bar{x} = \frac{1}{n} \sum_{i=1}^n X_i$

Def. Выборочной дисперсией D^* называется величина $D^* = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{x})^2$ (или $D^* = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{x}^2$)

По закону больших чисел выборочное среднее будет сходиться к матожиданию

Def. Исправленной дисперсией называется величина $S^2 = \frac{n}{n-1} D^* = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{x})^2$

Def. Выборочной функцией распределения $F^*(x)$ называется функция $F^*(x) = \frac{\text{число данных } x_i < x}{n}$

Th. Выборочная функция распределения поточечно сходится к теоретической функции распределения:

$$\forall y \in \mathbb{R} F^*(y) \xrightarrow{p} F(y)$$

$$F(y) = P(X < y)$$

$$F_y^* = \frac{1}{n} \sum_{i=1}^n I(X_i < y) \xrightarrow[\text{по ЗБЧ}]{p} EI(X_i < y) = P(X_i < y) = P(X_1 < y) = F_{X_1}(y)$$

Усилим теорему

Th. Гливенко-Кантелли. $\sup_{x \in \mathbb{R}} |F^*(x) - F(x)| \xrightarrow{p} 0$

Th. Колмогорова. $\sqrt{n} \sup_{x \in \mathbb{R}} |F^*(x) - F(x)| \rightrightarrows K$ – распределение Колмогорова с функцией распределения $F_K(x) = \sum_{j=-\infty}^{\infty} (-1)^j e^{-2j^2 x^2}$, $x \in [0; \infty)$

Начальная обработка статданных

1. Ранжирование данных – упорядочиваем выборки по возрастанию. В результате получаем вариационный ряд $\vec{X} = (X_{(1)}, X_{(2)}, \dots, X_{(n)})$

$$X_{(1)} = \min X_i; \quad X_{(n)} = \max X_i$$

$X_{(i)}$ – i -ая порядковая статистика

2. Объединим повторяющиеся данные – получаем т.н. частотный вариационный ряд

X_i	$X_{(1)}$	$\dots$	$X_{(r)}$	$\sum$
n_i	n_1	$\dots$	n_r	n

Иногда часть данных отбрасывается сверху и снизу (по 5, по 10, по 5% и так далее), чтобы сделать выборку репрезентативной

$$\text{Тогда } \bar{x} = \frac{1}{n} \sum X_i n_i, \quad D^* = \frac{1}{n} \sum (X_i - \bar{x})^2 n_i$$

3. Чтобы уменьшить количество вычислений или сделать гистограмму, делают интервальный вариационный ряд: разбиваем данные на интервалы и считаем, сколько данных n_i попало в интервал.

Тогда n_i – частота интервала A_i

Есть два основных способа разбиения на интервалы:

- (а) Интервалы одинаковой длины
- (б) Равнонаполненные интервалы (в каждом интервале примерно одинаковое количество данных)

Число интервалов K такое, что $\frac{K(n)}{n} \rightarrow 0$ и $K(n) \xrightarrow{n \rightarrow \infty} \infty$

Обычно применяют формулу Стерджесса $K \approx 1 + \log_2 n$ или $K \approx \sqrt[3]{n}$


Пусть получили интервальный вариационный ряд

интервалы	$[a_0; a_1)$	$[a_1; a_2)$	$\dots$	$[a_{K-1}; a_K]$	$\sum$
частоты	n_1	n_2	$\dots$	n_K	n

Геометрическая интерпретация данных

- Гистограмма

Строится ступенчатая фигура из прямоугольников, основание i -ого прямоугольника – интервал, высота прямоугольника – $\frac{n_i}{nl_i}$, где l_i – длина интервала




Визуально можно сделать гипотезу, как ведет себя распределение.

Th. Гистограмма поточно сходится к теоретической плотности


• Полигон

На оси абсцисс отмечаем значения частотного вариационного ряда, по оси ординат – их частоты. Получившиеся точки соединяем отрезками



• Выборочная функция распределения

На основе таблицы строится график функции распределения



Она может быть ступенчатой, ломаной или соединена по усмотрению